



**Tecnológico
de Monterrey**

10. Estadística descriptiva y análisis exploratorio

Ciencia de datos para la toma de decisiones I

**Jorge
Juvenal
Campos Ferreira**

✉ juvenal.campos@tec.mx

Motivación: ¿Por qué explorar datos?

Modelar sin explorar


- **GIGO**: Garbage In, Garbage Out
- No ves datos faltantes (**NAs**)
- **Outliers** afectan modelos
- Conclusiones incorrectas



<https://medium.com/nyc-design/gigo-garbage-in-garbage-out-concept-for-ux-research-7e3f50695b82>

Con exploración (EDA: Análisis exploratorio)

- Entiende **estructura** de datos
- Identifica **patrones** y **anomalías**
- Detecta y maneja **outliers**
- Modelos más **robustos**



<https://www.instagram.com/reel/DCVqZU0SCLS/>

Medidas de centralidad

¿Hacia dónde está el "centro" de tus datos?

Media (mean)

Suma / número de elementos. Sensible a outliers

Mediana (median)

Valor del centro. Robusta a outliers

Moda (mode)


Valor más frecuente. Para datos categóricos

Rango medio

$(\min + \max) / 2$. Muy sensible a extremos

Ejemplo en R:

```
mean(datos$ingresos) # 45000
median(datos$ingresos) # 38000
mode(datos$región) # "Centro"
range(datos$ingresos) # min y max
```



Medidas de dispersión

¿Cuánta variabilidad hay en los datos?

Varianza (var)

Promedio de desviaciones al cuadrado

Desv. estándar (sd)

Raíz de varianza. Mismas unidades que datos

Coef. variación (CV)

sd / mean. Para comparar escalas distintas

Rango

max - min. Distancia entre extremos

Desviación media

promedio de las distancias de cada dato (respecto a la media. Es decir, cuánto se aleja un valor típico de la media, **en promedio**).

Ejemplo en R:

```
var(datos$ingresos) # 2000000000
sd(datos$ingresos)  # 44721
cv <- sd(datos$ingresos) / mean(datos$ingresos) # 0.99
range(datos$ingresos) # 5000 950000
```


Medidas de dispersión

$$\text{Rango} = X_{\max} - X_{\min}$$

$$D_m = \frac{\sum_1^k f_i |\dot{x} - \bar{x}|}{n}$$

$$\sigma^2 = \frac{\sum_1^k f_i (\dot{x} - \bar{x})^2}{n}$$

$$\sigma = \sqrt{\sigma^2}$$




Distribuciones de datos

¿Cómo se distribuyen los datos alrededor del centro?


Normal (campana)

Simétrica, pico en centro, colas iguales




Sesgada derecha

Cola larga a derechas (ingresos típicos)




Sesgada izquierda

Cola larga a izquierda (raros valores bajos)



Bimodal

Dos picos: mezcla de dos grupos



Detectar distribuciones:

```
hist(datos$ingresos)    # Visualizar  
qqnorm(datos$ingresos)  # Comparar con normal  
skewness(datos$ingresos) # Sesgo (-/0/+)
```

Cuartiles y percentiles


Divide datos ordenados en secciones

Visualización:

- Q1 (25%)
- Q2 (50%, mediana)
- Q3 (75%)
- Q4 (100%, máximo)


Ejemplo: ingresos de 100 personas:

- Q1=30k (25% ganan menos)
- Q2=45k (mitad)
- Q3=70k (75% menos)
- Q4=950k (máximo)



Rango intercuartílico (IQR) = Q3 - Q1

```
quantile(datos$ingresos) # Q0, Q1, Q2, Q3, Q4  
IQR(datos$ingresos)      # Q3 - Q1  
boxplot(datos$ingresos)  # Visualizar
```



Función `summary()`: Todo de un vistazo

`summary()` proporciona un resumen estadístico instantáneo

Para vectores numéricos:

```
summary(datos$ingresos)
Min. 1st Qu. Median Mean 3rd Qu. Max
5000 30000 45000 45500 70000 950000
```

Para tibbles/data frames:

```
summary(datos)
# Resumen de TODAS las columnas
# Min, Q1, Med, Mean, Q3, Max para números
# Conteos para factores
```

Retorna:

Min

Valor mínimo

1st Qu

Percentil 25, Cuartil 1

Median

Percentil 50

Mean

Media aritmética

3rd Qu

Percentil 75, cuartil 3

Max

Valor máximo

NA's

Conteo valores faltantes


Detección y manejo de outliers

Método 1: Regla de $1.5 * IQR$

```
Q1 <- quantile(datos$x, 0.25)
Q3 <- quantile(datos$x, 0.75)
IQR <- Q3 - Q1
lower <- Q1 - 1.5 * IQR
upper <- Q3 + 1.5 * IQR
outliers <- datos$x[datos$x < lower | datos$x > upper]
```

Método 2: Desviación estándar

```
mean_x <- mean(datos$x, na.rm=TRUE)
sd_x <- sd(datos$x, na.rm=TRUE)
outliers <- datos$x[
  abs(datos$x - mean_x) > 3 * sd_x
]
```



Decisiones:

- ¿Son valores reales? Verificar en datos originales
- ¿Son errores de captura? Eliminar o imputar (rellenar con algún otro dato).
- ¿Son valores válidos pero extremos? Mantener y documentar




Análisis de correlación

¿Se mueven juntas dos variables?


```
cor(datos$ingreso, datos$educación) # Resultado: 0.75  
# Entre -1 (negativa perfecta) y +1 (positiva perfecta)  
cor(datos[, c("ingresos", "educación", "edad")]) # Matriz de correlación 3x3
```

**Correlación Negativa
Perfecta**




$$r_{xy} = -1$$

**Correlación Negativa
Fuerte**




$$r_{xy} = -0,9$$

**Correlación Negativa
Débil**




$$r_{xy} = -0,2$$

Correlación Nula




$$r_{xy} = 0$$

**Correlación Positiva
Débil**




$$r_{xy} = 0,2$$

**Correlación Positiva
Fuerte**



$$r_{xy} = 0,9$$

**Correlación Positiva
Perfecta**



$$r_{xy} = 1$$

Tipos de datos faltantes (NAs)



Missing Completely At Random

La probabilidad de que falte un dato NO depende de ninguna variable (ni observada ni no observada).

Ejemplo:

Se caen encuestas al azar al transportarlas.

Sin sesgo. Solo se pierde potencia estadística.

Benigno



Missing At Random

La probabilidad de que falte depende de otras variables observadas, pero NO del valor faltante mismo.

Ejemplo:

Las mujeres reportan menos su ingreso que los hombres, pero dentro de cada sexo no depende del ingreso real.

Manejable con imputación múltiple o modelos condicionales.

Manejable



Missing Not At Random

La probabilidad de que falte depende del propio valor no observado.

Ejemplo:

Personas con ingresos muy altos no los reportan precisamente por ser altos.

Requiere modelos de selección o análisis de sensibilidad.

Problemático

Manejo de datos faltantes (NA)

Detectar

```
is.na(datos$edad)    # Vector T/F  
sum(is.na(datos$edad)) # Conteo  
colSums(is.na(datos)) # Por columna
```

Manejar

```
# En funciones, usar na.rm=TRUE  
mean(datos$edad, na.rm=TRUE)  
sum(datos$gastos, na.rm=TRUE)  
  
# O eliminar filas con NA  
data_clean <- na.omit(datos)
```

Opciones:

Eliminar

Si pocos NA (< 5%)

Imputar media

Si datos MCAR (Missing Completely At Random)

Imputar mediana

Más robusta que media

EDA integral: Flujo de trabajo

1. Cargar datos




`dim(), head(), str()`

2. Valores faltantes



`sum(is.na(datos))`

3. Estadísticas




`summary(datos)`


4. Visualizar



5. Buscar outliers



6. Correlaciones



`cor(), corplot()`

Resumen

- 1. EDA antes de modelar: evita GIGO y conclusiones incorrectas
- 2. Medidas centrales (media, mediana) describen el centro
- 3. Medidas de dispersión (varianza, sd) describen la propagación
- 4. Cuartiles dividen datos en secciones de 25%
- 5. Outliers pueden ser reales o errores: investiga
- 6. Correlación entre variables: cuidado con causalidad espuria
- 7. `summary()` da visión general rápida de datos

Ejercicio práctico 01.

- Cargue los datos que se encuentran en la carpeta del ejercicio 01 de la sesión 10.
- 1. Explore los datos. ¿Cuántas filas tienen? ¿Cuántos renglones? ¿Cuáles son los nombres de las variables? ¿Cuáles son numéricas? ¿Cuáles son categóricas?
- 2. Aplique a la tabla la función ***summary()***. ¿Qué resultado le arroja?
- 3. Obtenga la **media** sólo del ingreso mensual.
- 4. Detecte las variables numéricas. Genere una tabla nueva con esas variables. Grafique su distribución usando ***geom_density*** y un arreglo de facetas.

Ejercicio práctico 01.

- 5. Ahora haga un boxplot con ***geom_boxplot*** e identifique los outliers
- 6. Obtenga la correlación entre el ingreso mensual y los gastos mensuales. También haga la gráfica correspondiente con ***geom_point()*** y verifique gráficamente esta respuesta.
- 7. Diagnostique el tipo de NAs que tiene cada una de las variables. ¿Qué hacer en cada caso? Si detecta algún caso de NAs tipo MCAR y MAR *impute* los valores faltantes.