



**Tecnológico
de Monterrey**

11. Causalidad en ciencias sociales

Ciencia de datos para la toma de decisiones I

**Jorge
Juvenal
Campos Ferreira**

✉ juvenal.campos@tec.mx

El dilema de la evaluación de políticas públicas

Programa de becas:

Imagina que eres jef@ de la Secretaría de Educación de un estado mexicano.

Tu gobernador implementó un programa de becas hace dos años. Ahora quiere saber:

¿funcionó el programa? Se van a tomar decisiones presupuestarias cruciales basadas en tu respuesta.

Suponga que entrega municipios beneficiarios tienen 15% más tasa de graduación

¿Pregunta central:

- ¿Causó el programa ese aumento?
- ¿O se graduarían de todas formas porque tienen mejor infraestructura?
- ¿Los municipios beneficiarios ya eran diferentes?




Correlación vs Causalidad

1

Correlación


Dos variables se mueven juntas



2

Causalidad

Un cambio en X causa cambio en Y



Ejemplo: tamaño de zapatos vs inteligencia (correlacionados en niños, pero causa=edad)

REGLA: Correlación no implica **causalidad**, pero **causalidad** requiere **correlación**



LA CORRELACIÓN NO IMPLICA CAUSALIDAD



1

Las ventas de helado y los ataques de tiburón aumentan en verano.

2

A pesar de la correlación, una NO causa la otra.

3

Días soleados y calurosos contribuyen a un mayor consumo de helados, al igual que más personas en la playa, lo que aumenta la probabilidad de ataques de tiburón.

@AprenderEstadisticaFacil_

¿Cómo logramos probar causalidad?

- 1. Asociación (correlación).** X y Y deben estar relacionados estadísticamente. Esto es lo más fácil de verificar — si no hay correlación, difícilmente hay causalidad. Pero es solo el punto de partida, porque correlación $\neq$ causalidad.
- 2. Precedencia temporal.** La causa debe ocurrir antes que el efecto. X tiene que preceder a Y en el tiempo.
- 3. Eliminación de explicaciones alternativas.** Este es el requisito difícil. Necesitas descartar que la relación observada entre X y Y se deba a una tercera variable (*confusor*), a causalidad inversa, o a sesgos de selección.

¿Cómo logramos eliminar explicaciones alternativas?

Experimento aleatorizado (RCT): el estándar de oro. La aleatorización rompe por diseño la relación entre el tratamiento y los confusores.

Cuasi-experimentos: cuando no puedes aleatorizar, usas diseños que explotan alguna variación "como si fuera" aleatoria — diferencias en diferencias, variables instrumentales, regresión discontinua, controles sintéticos.

Ajuste por observables: controlar por confusores identificados en el DAG (matching, regresión). Funciona solo si tu DAG es correcto y no hay confusores no observados.

Variables confusoras (confounders)

Una **variable confusora** es una variable que afecta tanto a X (tratamiento) como a Y (resultado)

Ejemplos de variables confusoras en el programa de becas:

**Ingreso
familiar**

Afecta selección de municipios **y** a la tasa de graduación

**Infraestructura
escolar**

Afecta dónde se implementan becas **y** el éxito del programa


**Experiencia
docente**

Afecta ambos: asignación de recursos **y** los resultados

DAGs: Gráficos acíclicos dirigidos

DAG = diagrama que muestra relaciones causales entre variables.
Ayudan a entender los mecanismos de causalidad.

Ejemplo: Programa de becas



*Los diagramas DAG ayudan a identificar variables confusoras y aquellas posibles variables que hay que **controlar** estadísticamente.*

DAGs: Ejercicio práctico #1

E1. Elabore el DAG para la siguiente afirmación: “los países que consumen más chocolate tienen más premios Nobel”. Identifiquen el *confusor* y expliquen por qué la relación no es causal.

E2. Imagine que quiere analizar “el efecto de las horas de estudio sobre su calificación”. ¿Cómo sería el mecanismo causal? ¿Qué otras variables confusoras hay que considerar? ¿Cual sería el DAG?

E3. Suponga que quiere obtener un DAG para entender como llegar al éxito profesional. ¿Qué variables habría que considerar? ¿Cómo las podría medir?

Contrafactuales: mundos posibles

Efecto causal = Resultado CON tratamiento - Resultado SIN tratamiento

Mundo factual (real, observado)

- El municipio recibe becas
 - Tasa de graduación: 70%
 - Esto observamos
- Pero ¿qué hubiera pasado sin becas?*



Mundo contrafáctico (imaginado, no observado)

- El municipio NO recibe becas
- Tasa de graduación estimada: 55%
- Nunca lo observamos



Efecto causal =



—



EFFECTO CAUSAL
(15%)



1. Modelo Causal de Rubin

Para cada unidad de análisis, existen resultados potenciales bajo distintos tratamientos o condiciones.

La **causalidad** (bajo este modelo) se define como *la diferencia entre lo que le pasaría a una unidad si recibe el tratamiento y lo que le pasaría si no lo recibe.*

El problema fundamental: nunca podemos observar ambos resultados al mismo tiempo para la misma unidad.

Observado



Contrafactual



Efecto causal =



—



⇒



**EFFECTO CAUSAL
(15%)**

Potencial de outcomes (potential outcomes)

Cada unidad de análisis (municipio, estudiante) tiene dos posibles resultados:

Notación matemática:

$Y(1)$ = resultado de la variable objetivo (graduación) si recibe tratamiento (becas)

$Y(0)$ = resultado de la variable objetivo (graduación) si no recibe tratamiento (becas)

Efecto del tratamiento = $Y(1) - Y(0)$

EL PROBLEMA FUNDAMENTAL:

Cada unidad observa solo $Y(1)$ o $Y(0)$, nunca ambos

Inferencia causal = *estimar el $Y(1)$ o $Y(0)$ que no vimos usando supuestos estadísticos*

Sesgo de selección

Ocurre cuando los municipios que reciben becas son sistemáticamente diferentes

¿Quién fue seleccionado para recibir becas?

Opción A: Aleatorio

Por sorteo (sin sesgo)

Opción B: Por necesidad

Los municipios más pobres (probable sesgo negativo)

Opción C: Por capacidad

Los municipios con mejor infraestructura (sesgo positivo)

Solución 1: Experimentos aleatorizados (RCT)

Randomized Controlled Trial: la asignación por sorteo elimina sesgos de selección.
Similar a los ensayos clínicos con los que se prueban las medicinas.

1

Grupo Tratamiento



200 municipios reciben becas (**sorteo**)

2

Grupo Control



200 municipios no reciben (**sorteo**)


Ventaja: Entre más grande sea cada grupo, tendrán estadísticas similares, con lo que podremos hacer la comparación entre grupos y obtener el tamaño del efecto del tratamiento.

Solución 2: Métodos *cuasi*experimentales

Cuando no puedes hacer RCT, usa métodos que imitan experimentos:


Diferencias en diferencias (diff en diff)

Compara cambios en municipios tratados vs control




Regresión discontinua

Explota corte en criterio de selección



Matching propensity score

Empareja unidades similares (con vs sin tratamiento)



Variables instrumentales

Usa variable exógena que afecte tratamiento



Experimentos naturales

Situación donde algún evento externo — que no fue diseñado como experimento — genera una asignación al "tratamiento" que es efectivamente aleatoria o cuasi-aleatoria.

Es decir, la vida *"te regala"* algo parecido a un experimento controlado sin que nadie lo haya planeado. **Si no puedes aleatorizar tú (porque sería antiético, imposible o muy caro), buscas situaciones donde algo ya lo hizo por ti.** 🤔

El **servicio militar obligatorio en Vietnam** se asignaba por lotería de cumpleaños. Angrist (1990) usó eso para estimar el efecto de servir en el ejército sobre los ingresos futuros. El número de lotería es aleatorio, así que es como si la naturaleza hubiera asignado el tratamiento. Resultado: los veteranos ganaban un 15% menos que los no-veteranos comparables.

Card y Krueger (1994) compararon empleo en restaurantes de comida rápida entre Nueva Jersey (que subió el salario mínimo) y Pennsylvania (que no). La frontera estatal creó un grupo de tratamiento y uno de control sin intervención experimental. Comparado con los restaurantes en Pennsylvania, los de comida rápida en Nueva Jersey aumentaron su empleo en 13%

PROGRESA/Oportunidades y su implementación escalonada. Progresá fue el primer programa nacional de transferencias condicionadas del mundo, implementado en 1997, y su fase inicial se diseñó como un experimento aleatorizado. Pero más allá del RCT original, la expansión gradual del programa — que llegó a comunidades en distintos momentos — generó experimentos naturales para quienes no estaban en la muestra experimental. Parker y Vogl usaron un enfoque cuasi-experimental con datos censales para estimar los impactos de largo plazo, encontrando que los beneficiarios obtuvieron más escolaridad y mayores ingresos en la adultez.

El Seguro Popular (2004-2012). Se implementó de manera escalonada por municipios. Los municipios que lo recibieron primero funcionan como grupo de tratamiento y los que lo recibieron después como control. King et al. (2009) usaron esta variación para medir efectos sobre gasto catastrófico en salud. Resultados: los recursos del programa efectivamente llegaron a los pobres y los protegieron financieramente.

Supuestos clave de inferencia causal

- 1. El tratamiento de una unidad no afecta a otras
- 2. **Consistencia**: si recibes tratamiento, tu resultado es $Y(1)$
- 3. **Positividad**: todos tienen probabilidad > 0 de recibir tratamiento
- 4. **No confunders**: no hay variables no observadas que confundan
- 5. **Ignorabilidad**: selección no depende de resultados potenciales

Ejemplo: Política de salario mínimo

¿Aumentar el salario mínimo destruye empleos?

Correlación simple	Parece que sí (estados altos en min=empleo bajo)	NO confiable
Regresión con controles	Efecto pequeño, $p=0.08$	Mejor pero inseguro
Diferencias en diferencias	Efecto nulo (estudio Card-Krueger)	Evidencia fuerte

Resumen

- 1. Correlación no implica causación
- 2. Variables confusoras crean sesgo
- 3. **Contrafactuales**: qué hubiera pasado sin tratamiento
- 4. **RCT** es el *gold standard* pero no siempre posible
- 5. Los **cuasiexperimentos** y los **experimentos naturales** aproximan a los RCT
- 6. Siempre declare supuestos para inferencia causal

¿Preguntas?